

# 1 Elementos de Otimização

Neste documento estudaremos brevemente um problema geral de otimização em várias variáveis com destaque para os problemas de otimização sem restrições. Vamos supor que todas as funções envolvidas são contínuas e, pelo menos uma vez diferenciáveis.

## 1.1 Problema geral de otimização

Considere  $f(x)$  uma função contínua de várias variáveis a valores reais. Matematicamente, escrevemos que  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$ . O problema geral de otimização envolvendo  $f$  é definido por

$$\begin{aligned} &\text{minimizar} && f(x) \\ &\text{restrita a} && x \in \Omega, \end{aligned}$$

onde  $\Omega \subset D$  é um subconjunto do domínio de definição de  $f$ . A função  $f$  é chamada de função objetivo do problema. Se  $\Omega = \mathbb{R}^n$ , diremos que o problema de otimização é irrestrito, caso contrário, o problema será chamado de restrito.

Resolver um problema de otimização significa encontrar minimizadores. Existem dois tipos de minimizadores: os globais e os locais.  $x^* \in \Omega$  é um minimizador global do problema se  $f(x^*) \leq f(x)$  para todo  $x \in \Omega$ . No entanto,  $x^*$  será considerado minimizador local se  $f(x^*) \leq f(x)$  para todo  $x$  em uma vizinhança de  $x^*$ . É evidente que todo minimizador global é local mas a recíproca não é verdadeira. A Figura 1 ilustra o gráfico de uma função contínua de uma variável que possui um minimizador local e um global denotados por  $x_{\text{loc}}$  e  $x_{\text{glob}}$ , respectivamente.




Figura 1: Uma função  $f(x)$  com um minimizador local e um global.

Embora tenhamos definido o problema geral de otimização como sendo um problema de minimização, é possível convertê-lo em um problema de maximização pois, como  $f$  é contínua em  $D$ , minimizar  $f(x)$  em  $\Omega$  é equivalente a maximizar  $-f(x)$  em  $\Omega$ .

## 1.2 Otimização irrestrita

Nosso objeto de estudo neste documento é o problema de otimização sem restrições

$$\begin{aligned} &\text{minimizar } f(x) \\ &\text{restrita a } x \in \mathbb{R}^n, \end{aligned}$$

onde  $f$  é uma função diferenciável. Sabemos dos cursos de Cálculo que os candidatos à minimizadores desse problema satisfazem a condição  $\nabla f(x) = 0$ , onde  $\nabla f(x)$  é o vetor gradiente de  $f$  avaliado em  $x$ . Como nas aplicações reais os problemas de otimização contêm muitas variáveis, faz-se necessário o desenvolvimento de algoritmos que buscam soluções aproximadas para estes problemas. No que segue, denotaremos o produto escalar (interno) entre dois vetores  $u$  e  $v$  por  $u^T v$ .

Um algoritmo geral de resolução para o problema de otimização irrestrita associado a uma função objetivo diferenciável  $f(x)$  é baseado em uma direção de descida. Dizemos que um vetor  $d \in \mathbb{R}^n$  é uma direção de descida a partir de  $x \in \mathbb{R}^n$  se  $\nabla f(x)^T d < 0$ , ou seja, o ângulo que o vetor gradiente faz com o vetor  $d$  é obtuso ( $> 90^\circ$ ). Assim uma iteração de um algoritmo desse tipo consiste em, partindo de  $x$ , tomar  $d$  de descida e andar ao longo de  $d$  até que o valor da função  $f$  diminua. A Figura 2 ilustra algumas curvas de nível de uma função de duas variáveis  $f(x)$ . No ponto  $x$  o vetor gradiente  $\nabla f(x)$  é perpendicular à curva de nível que passa por  $x$ . O vetor  $d$  que sai de  $x$  é uma direção de descida pois faz ângulo obtuso com  $\nabla f(x)$ . Nesta figura o minimizador global de  $f(x)$  está representado por  $x^*$ .




Figura 2: Exemplo de direção de descida a partir de  $x$ .

Os principais passos de um algoritmo geral baseado em uma direção de descida são:

- 0: Dados  $f$  diferenciável e  $x_0 \in \mathbb{R}^n$ , faça  $k = 0$ .
- 1: Enquanto  $\nabla f(x_k) \neq 0$ :
- 2:    calcule a direção de descida  $d_k$ ,
- 3:    determine  $\alpha_k > 0$  tal que  $f(x_k + \alpha_k d_k) < f(x_k)$ ,
- 4:    faça  $x_{k+1} = x_k + \alpha_k d_k$ ,  $k = k + 1$  e volte ao passo 1.
- 5: Fim

Os passos 2, 3 e 4 do algoritmo devem ser repetidos até que se obtenha  $x_k$  tal que  $\nabla f(x_k) = 0$ . O cálculo de  $\alpha_k$  no passo 3 é chamado de Busca Linear. Em alguns casos, é possível realizar a Busca Linear Exata, ou seja, encontrar  $\alpha_k$  que minimiza  $f(x)$  ao longo de  $d_k$  partindo de  $x_k$ . A forma como a direção  $d_k$  é calculada em cada iteração define o tipo de algoritmo utilizado. Veremos a seguir duas escolhas particulares para  $d_k$  que dão origem ao Método do Gradiente e ao Método de Newton.

### 1.3 Método do Gradiente

O método mais comum para otimização irrestrita e também muito utilizado em problemas de inteligência artificial é o Método do Gradiente, também conhecido como Método da Máxima Descida. No contexto do algoritmo geral que discutimos anteriormente, basta tomar em cada iteração  $d_k = -\nabla f(x_k)$ . Sabemos dos cursos de Cálculo que ao longo dessa direção  $d_k$  a função  $f(x)$  diminui mais rapidamente, partindo de  $x_k$ .

Se a função a ser minimizada for uma função quadrática com matriz hessiana definida positiva, podemos escrever  $f$  como

$$f(x) = \frac{1}{2}x^T A x - b^T x + c.$$

Neste caso temos que  $\nabla f(x) = Ax - b$  e  $\nabla^2 f(x) = A$  é uma matriz simétrica é definida positiva, ou seja, seus autovalores são todos números reais positivos. Para esta função  $f$  é possível mostrar que o valor de  $\alpha_k$  na busca linear exata é dado por

$$\alpha_k = \frac{d_k^T d_k}{d_k^T A d_k}.$$

A Figura 1.3 ilustra a evolução do Método do Gradiente na tentativa de encontrar o minimizador global  $x^*$  de uma função quadrática  $f(x)$  de duas variáveis com matriz hessiana definida positiva. Nesta figura também podemos observar algumas curvas de nível de  $f(x)$ . Partindo de  $x_0$ , se unirmos os iterandos  $x_k$  por segmentos de reta, observaremos um caminho

no formato de zigue-zague que se aproxima de  $x^*$ . É possível mostrar, no caso da busca linear exata, que

$$\nabla f(x_k)^T \nabla f(x_{k+1}) = 0,$$

isto é, os vetores gradientes avaliados em dois iterandos consecutivos são ortogonais. Isso explica o comportamento ilustrado na figura.




Figura 3: Método do Gradiente aplicado em uma função quadrática.

No caso em que a função objetivo  $f$  não é quadrática, não existe fórmula fechada para o cálculo de  $\alpha_k$  e o sucesso do Método do Gradiente dependerá da estratégia a ser adotada para a busca linear e de propriedades específicas de  $f(x)$ .

- **Exemplo 1:** Considere a função  $f(x) = 3x_1^2 - 4x_1x_2 + 4x_2^2 + 2x_1 - 3x_2$ .

a) Calcule o vetor gradiente e a matriz hessiana de  $f(x)$ .

- ◇ **Solução:** Como a função  $f(x)$  tem duas variáveis, o vetor gradiente terá tamanho  $2 \times 1$  e a matriz hessiana terá tamanho  $2 \times 2$ . Assim,

$$\nabla f(x) = \begin{pmatrix} 6x_1 - 4x_2 + 2 \\ -4x_1 + 8x_2 - 3 \end{pmatrix} \quad \text{e} \quad \nabla^2 f(x) = \begin{pmatrix} 6 & -4 \\ -4 & 8 \end{pmatrix}.$$

b) Determine todos os pontos estacionários de  $f(x)$ .

- ◇ **Solução:** Chamamos de pontos estacionários aqueles que anulam o vetor gradiente. Logo, para calculá-los basta resolver a equação  $\nabla f(x) = 0$ . Igualando cada componente de  $\nabla f(x)$  a zero, obtemos o seguinte sistema de equações

$$\begin{cases} 6x_1 - 4x_2 = -2, \\ -4x_1 + 8x_2 = 3, \end{cases}$$

cujas soluções são  $x_1 = -0.125$  e  $x_2 = 0.3125$ . Como a função  $f(x)$  é quadrática e  $\nabla^2 f(x)$  é uma matriz simétrica e definida positiva, o único ponto estacionário encontrado é o minimizador global de  $f(x)$ . Portanto, em  $x^* = (-0.125, 0.3125)^T$  a função  $f(x)$  atinge o menor valor possível:  $f(x^*) = -0.59375$ .

c) Partindo de  $x_0 = (-1, 0.5)^T$ , faça uma iteração do método do gradiente com busca linear exata.

◇ **Solução:** Temos que  $d_0 = -\nabla f(x_0) = (6, -5)^T$ . O passo  $\alpha_0$  da busca linear exata é dado por

$$\alpha_0 = \frac{d_0^T d_0}{d_0^T A d_0} = 0.0929.$$

Portanto,

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} -1 \\ 0.5 \end{pmatrix} + 0.0929 \begin{pmatrix} 6 \\ -5 \end{pmatrix} = \begin{pmatrix} -0.4426 \\ 0.0355 \end{pmatrix}.$$

Para efeito de comparação, observe que  $f(x_0) = 2.5$  e  $f(x_1) = -0.3361$ , ou seja, em uma iteração o valor de  $f(x)$  foi diminuído.

## 1.4 Método de Newton

Considere uma função  $f$  duas vezes diferenciável e o problema de encontrar um minimizador para  $f$ . Seja  $x_k$  no domínio de  $f$  tal que  $\nabla f(x_k) \neq 0$ . Podemos utilizar as derivadas de primeira e segunda ordens de  $f$  (contidas no vetor gradiente e na matriz hessiana, respectivamente) para construir uma aproximação quadrática de  $f(x)$  na vizinhança de  $x_k$ . Desta forma

$$f(x) \approx q(x) = f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k),$$

para  $x$  em uma vizinhança de  $x_k$ . Esta aproximação é a expansão de Taylor de segunda ordem de  $f(x)$  em torno de  $x_k$ .

O método de Newton substitui, em cada iteração, o problema de minimizar  $f(x)$  pelo problema de minimizar  $q(x)$ . Como  $q(x)$  é uma função quadrática, o candidato a ponto de mínimo satisfaz  $\nabla q(x) = 0$ . Fazendo  $d = x - x_k$  na expressão de  $q(x)$ , podemos escrever

$$\nabla q(x) = 0 \Rightarrow \nabla^2 f(x_k) d = -\nabla f(x_k),$$

que é um sistema de equações lineares. Uma vez que  $d$  foi encontrado resolvendo o sistema, o novo vetor  $x_{k+1}$  será dado por  $x_{k+1} = x_k + \alpha_k d_k$ , onde  $\alpha_k$  é o tamanho de passo obtido por realizar uma busca linear ao longo de  $d_k$  para diminuir o valor de  $f$ . É importante observar que a matriz de coeficientes do sistema linear pode não admitir inversa e a resolução desse sistema pode não estar bem definida.

O algoritmo do Método de Newton pode ser resumido nos seguintes passos:

0: Dados  $f(x)$  duas vezes diferenciável e  $x_0 \in \mathbb{R}^n$ , faça  $k = 0$ .

1: Enquanto  $\nabla f(x_k) \neq 0$ :

2: determine  $d_k$  tal que  $\nabla^2 f(x_k)d_k = -\nabla f(x_k)$

3: encontre  $\alpha_k > 0$  tal que  $f(x_k + \alpha_k d_k) < f(x_k)$

4: faça  $x_{k+1} = x_k + \alpha_k d_k$ ,  $k = k + 1$  e volte ao passo 1.

5: Fim.

Observações:

- a) Se a matriz hessiana  $\nabla^2 f(x_k)$  for definida positiva, ela será invertível e a solução exata do sistema linear no passo 2 é dada por

$$d_k = [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Além disso, é possível mostrar que nessas condições  $d_k$  é uma direção de descida. Na prática deve-se evitar inverter a matriz hessiana para o cálculo de  $d_k$ , substituindo este cálculo pelo uso de um método numérico para resolução de sistemas lineares.

- b) Se  $f(x)$  for uma função quadrática com hessiana definida positiva, o algoritmo encontra o minimizador de  $f(x)$  em uma iteração, qualquer que seja  $x_0$  escolhido.
- c) Uma forma de evitar que na busca linear o passo dado produza pouco decréscimo no valor de  $f(x)$  é pedir que  $\alpha_k$  satisfaça a desigualdade

$$f(x_k + \alpha_k d_k) < f(x_k) + \lambda \nabla f(x_k)^T \alpha_k d_k,$$

com  $\lambda \in (0, 1)$  fixo. Esta desigualdade é chamada na literatura de condição de Armijo.

É sabido que o método de Newton possui convergência local, isto é, se  $x^*$  é um minimizador local de  $f(x)$  e  $\nabla^2 f(x^*)$  é definida positiva, se escolhermos  $x_0$  suficientemente próximo de  $x^*$ , a sequência de vetores gerada pelo algoritmo do método convergirá para  $x^*$  com taxa de convergência quadrática (considerada rápida em comparação a outros métodos para minimização de funções).

- **Exemplo 2:** Seja  $f(x) = (1 - x_1)^2 + 100(-x_1^2 - x_2)^2 + 1$ . Partindo de  $x_0 = (-1.2, 1)^T$ , faça uma iteração do método de Newton considerando o tamanho de passo  $\alpha_0 = 1$ .

- ◇ **Solução:** Primeiramente necessitamos do vetor gradiente e da matriz hessiana de  $f$  avaliados em  $x_0$ . Fazendo isso, obtemos:

$$\nabla f(x_0) = \begin{pmatrix} -1175.6 \\ 488.0 \end{pmatrix} \quad \text{e} \quad \nabla^2 f(x_0) = \begin{pmatrix} 2130 & -480 \\ -480 & 200 \end{pmatrix}.$$

Em seguida, devemos resolver o sistema linear  $\nabla^2 f(x_0)d_0 = -\nabla f(x_0)$  para obter a direção de descida  $d_0 = (0.0044, -2.4292)^T$ . Como  $\alpha_0 = 1$ , o resultado da primeira iteração do método é

$$x_1 = x_0 + d_0 = \begin{pmatrix} -1.1955 \\ -1.4292 \end{pmatrix}.$$

Os valores de  $f(x)$  em  $x_0$  e  $x_1$  são, respectivamente,  $f(x_0) = 601.2$  e  $f(x_1) = 5.82022$ .

Quando utilizamos  $\alpha_k = 1$  em uma iteração do método, dizemos que o passo dado foi “puro”. Os *softwares* que implementam o método de Newton costumam empregar uma estratégia para controlar o tamanho de  $\alpha_k$ . A Figura abaixo ilustra a evolução do método aplicado à função do Exemplo 2, partindo de  $x_0 = (-1.2, 1)^T$ . O minimizador global de  $f$  é  $x^* = (1, -1)^T$  e também está indicado na figura juntamente com algumas curvas de nível de  $f$ . O cálculo de  $x_1$  foi feito com um passo puro ( $\alpha_0 = 1$ ) como vimos no Exemplo 2, mas no cálculo dos demais iterandos  $x_k$  o tamanho de  $\alpha_k$  foi controlado ao longo das iterações. É possível observar que a sequência de vetores está convergindo para  $x^*$ .




Figura 4: Método de Newton com controle de passo.

## Bibliografia

1. Elementos de Programação Não Linear - A. Friedlander - Editora da Unicamp, 1994.
2. Numerical Optimization - J. Nocedal, S. J. Wright - Springer, 2006.

3. Linear and Nonlinear Programming - D. Luenberger, Y. Ye - Springer, 2010.